

Lista de links oficiais e repositórios (atualizados e prioritários)

Documentação oficial IplanRio / Escritório de Dados

- <https://docs.dados.rio/introduction> — Visão geral da infraestrutura de integração municipal (Data Lake + APIs + ferramentas).
- <https://docs.dados.rio/lms.txt> — Índice completo de toda a documentação (use para descoberta sistemática).
- <https://docs.dados.rio/data-lake/overview.md> — Data Lake Municipal.
- <https://docs.dados.rio/data-lake/tipos-de-pipeline/extracao-e-carga-de-dados.md> — Extração e carga (ETL/ELT).
- <https://docs.dados.rio/data-lake/tipos-de-pipeline/transformacao-dos-dados.md> — Transformação (dbt).
- <https://docs.dados.rio/data-lake/tipos-de-pipeline/criacao-de-pipelines.md> — Criação de pipelines.
- <https://docs.dados.rio/data-lake/prefect/construindo-uma-pipeline.md> — Prefect 3.
- <https://docs.dados.rio/data-lake/guia-de-estilo/convencoes-datasets-e-tabelas.md> — Convenções de nomenclatura.
- <https://docs.dados.rio/api-reference/overview> — APIs municipais (Busca, Catálogo, eAI Agent, Surkai, RMI etc.).
- <https://www.dados.rio/datalake> — Portal do Datalake (acesso, catálogo, treinamentos).
- <https://data-catalog.ipan.dados.rio/> — Catálogo de Dados interativo (schemas, BigQuery links).
- <https://cloud.google.com/customers/intl/pt-br/escritorio-de-dados-da-cidade-do-rio-de-janeiro> — Case Google Cloud (métricas: 41,3 TB, 9,5 TB processados/dia, etc.).

Repositórios GitHub (prefeitura-rio)

- <https://github.com/prefeitura-rio/pipelines> — Repositório central de pipelines Prefect (labels como `ri-j-sme`).
- https://github.com/prefeitura-rio/pipelines_rj_sms — Pipelines dedicados e bem documentados da SMS (referência de maturidade).
- https://github.com/prefeitura-rio/pipelines_v3_rj_sms — Versão Prefect v3 da SMS.
- <https://github.com/prefeitura-rio/queries-datario> — Modelos dbt públicos + metadata.json (tabelas de educação: escola, aluno_turma, notas, movimentações; owner SME, publisher Nuno Caminada Silva).

- <https://github.com/prefeitura-rio/data-catalog> — Código-fonte do Data Catalog (Astro + GCS).
- <https://github.com/prefeitura-rio> — Organização completa (208+ repositórios).
- <https://raw.githubusercontent.com/prefeitura-rio/queries-datario/master/metadata.json> — Metadados brutos das tabelas públicas de educação.

Outros relevantes

- <https://services.app.dados.rio> — Base URL das APIs de produção (exemplo de busca com coleção "sme").
 - <https://educacao.prefeitura.rio> — Portal SME (sistemas, LGPD, resoluções).
 - data.rio / ArcGIS — Dados geoespaciais de escolas e limites de CRE (junção manual com BigQuery).
-

Análise estruturada: do ETL ao MCP (cadeia completa SME-RJ no Data Lake IplanRio)

1. Resumo Executivo

A infraestrutura compartilhada (GCS + BigQuery + Prefect + dbt) é sólida e reconhecida (case Google Cloud). Dados de frequência, boletins, matrículas e Censo Escolar já existem no Lake. Porém, a SME opera com **opacidade elevada** em comparação com a SMS: pipelines diluídos por label (`rj-sme`), ausência de repositório dedicado público, catálogo parcial, linhagem incompleta e ausência de camada de produtos de dados / agentes especializados. O fluxo ETL → Transformação → Catálogo → Consumo → MCP existe, mas a maturidade decresce drasticamente após a camada bronze/silver. Resultado: excelente “infraestrutura de dados”, fraca “camada de produtos e agentes educacionais”.

2. Árvore de Investigação (Prioridade = Impacto × Incerteza × Relevância)

1. **Fontes de origem** (Escola 3.0, Diário, Matrícula Carioca, Trilhas, Censo INEP) → cobertura real de ETL?
2. **Pipelines Prefect** (label `rj-sme`) → schedules, testes, ownership, data freshness?
3. **Modelos dbt / camadas bronze-silver-gold** → views materializadas de risco de abandono, recomposição, equidade territorial?
4. **Catálogo e metadados** → cobertura, linhagem, qualidade?

- 5. Governança e acesso → LGPD vs. sandbox agregados?
- 6. Consumo inteligente → APIs Busca (coleção “sme”), eAI Agent, MCP servers?
- 7. Assimetria SMS vs SME → por que Saúde tem repositórios dedicados e Educação não?

3. Estado da Arte e Arquitetura Confirmada

- **Storage/Processamento:** Google Cloud Storage + BigQuery (projeto principal rj-iplanrio + datasets específicos).
- **Orquestração:** Prefect (central em prefeitura-rio/pipelines).
- **Transformação:** dbt (modelos em queries-datario e privados).
- **Catálogo:** data-catalog.iplan.dados.rio + repositório GitHub.
- **Consumo:** APIs (Busca com coleção "sme" , eAI Agent ainda pouco documentado), Metabase, Looker, possíveis MCP genéricos (mcp-bigquery , mcp-prefect , mcp-busca).
- **Integração inter-secretaria:** SMS + SME (saúde escolar) citada oficialmente.

4. Análise ponto a ponto: ETL → MCP

Camada	O que existe (evidência)	Lacunas / Problemas	Maturidade vs SMS
Extração & Carga (ETL/ELT)	Pipelines Prefect com label rj-sme . Censo Escolar citado explicitamente. Dados de frequência, boletins e matrículas confirmados no case Google Cloud e metadata.json.	Cobertura incompleta/não documentada de Escola 3.0, DiáRio, Trilhas e Matrícula Carioca. Sem repositório dedicado. Schedules e owners pouco visíveis.	Baixa (SMS tem pipelines_rj_sms + pipelines_v3_rj_sms com README, Poetry/uv, Infisical, localrun)
Transformação (dbt)	Modelos públicos em queries-datario (schema educacao_basica : escola, aluno_turma, notas, movimentações). Publisher Nuno Caminada Silva.	Ausência de evidência pública de testes dbt, Great Expectations, data freshness monitors ou marts de risco/recomposição. Linhagem incompleta.	Média-baixa

Armazenamento & Camadas	Bronze (staging) → Silver/Gold via dbt no BigQuery.	Risco de “data swamp” parcial (qualidade e completude variáveis). Dados sensíveis de alunos exigem escopos LGPD rigorosos.	Boa infraestrutura compartilhada
Catálogo & Metadados	Data Catalog funcional + metadata.json com descrições de tabelas educacionais.	Cobertura parcial. Dependência de conhecimento tácito (contatos).	Média
Governança & Acesso	Conta @prefeitura.rio ou Gmail + solicitação formal (Discord #peça-permissão). JWT Identidade Carioca.	Sem sandbox público de dados agregados/anonimizados. Alto atrito para experimentação (Impact Lab, pesquisa).	Similar (restrito), mas SMS mais visível
Consumo & Produtos de Dados	APIs de Busca (coleção "sme"), eAI Agent (página ainda vazia), Trilhas como sistema de aplicação.	Ausência de data products bem definidos (ex.: visão consolidada de risco de abandono por CRE, painel de recomposição, indicadores de equidade territorial). Junção geoespacial (data.rio) ainda manual.	Baixa
MCP / Agentes	MCP servers genéricos (mcp-bigquery , mcp-prefect , mcp-busca com coleção “sme”).	Nenhum MCP server especializado em educação (resumo de desempenho, priorização Trilhas, risco por CRE). eAI Agent pouco documentado.	Baixa

5. Debate dos Especialistas (adaptado)

- **Data Engineering / MLOps:** A infraestrutura compartilhada é correta e escalável. O modelo “pipelines colaborativos no repo central” só funciona quando a secretaria investe em documentação e ownership. SME investiu menos (ou de forma mais fechada).
- **Data Governance:** Proteção LGPD de dados de crianças é necessária e correta. A ausência de datasets agregados públicos ou sandboxes cria freio artificial à inovação.

- **Produto de Dados / IA:** O Lake é forte em armazenamento; fraco em consumo inteligente. Trilhas é sistema de aplicação, não camada analítica/IA exposta.
- **Red Team:** A assimetria SMS vs SME não é apenas técnica — é organizacional e de priorização. Conhecimento ainda está nas pessoas (Nuno Caminada como publisher recorrente).

6. Red Team e Limitações Críticas

- Data leakage / qualidade: Sem evidência pública de testes automatizados robustos.
- Domain shift / freshness: Monitoramento específico de educação não visível.
- Overfitting de infraestrutura: Excelente base, subutilizada em produtos finais.
- Comparação injusta: SMS tem volume e pressão operacional diferentes; ainda assim, a diferença de documentação é gritante.
- Custo de descoberta: Time externo ou novo interno leva semanas só para mapear o que existe.

7. Lacunas de Pesquisa e Oportunidades de Inovação

1. Mapear cobertura real de pipelines π_j -sme (requer acesso interno).
2. Criar/contribuir repositório ou documentação pública de pipelines SME.
3. Desenvolver MCP tools específicas de educação.
4. Propor datasets agregados e anonimizados para uso externo.
5. Construir marts de risco de abandono + recomposição + equidade territorial (cruzando com SMS e dados geoespaciais).
6. Documentar linhagem completa e data quality scores no Data Catalog.

8. Arquitetura/Metodologia Recomendada (próximos passos)

1. **Curto prazo:** Inventário completo de flows Prefect com label π_j -sme + publicação de README mínimo.
2. **Médio prazo:** Marts dbt de produtos de dados educacionais + testes de qualidade + freshness.
3. **Longo prazo:** MCP server especializado + agentes pedagógicos/gestão de CRE + sandbox de dados agregados.
4. **Governança:** Datasets públicos agregados + ambiente de exploração controlado.

9. Plano Experimental Sugerido

- Fase 0: Acesso formal + inventário (2–4 semanas).
- Fase 1: Documentação e catálogo (contribuição open).
- Fase 2: Protótipo de MCP + 2–3 marts prioritários.
- Fase 3: Avaliação de impacto (uso por CREs, redução de atrito para analistas, contribuição para Impact Lab).

10. Conclusão com nível de confiança

O GCP/Data Lake da SME-RJ **existe e é funcional**. A infraestrutura compartilhada da IplanRio é de alta qualidade. O principal problema não é ausência de dados ou tecnologia — é **opacidade, desigualdade de maturidade e ausência de camada de produtos/agentes**. Isso cria o paradoxo de um dos Data Lakes municipais mais avançados do Brasil convivendo com barreiras significativas de descoberta e consumo para a secretaria responsável por ~650 mil estudantes.

Nível de confiança: 0,85 (alta nas lacunas de documentação e assimetria com SMS; média-alta na extensão real dos datasets privados, pois o acesso pleno é restrito).

Este mapeamento serve como base diagnóstica para priorização interna, contribuições open-source ou propostas para Claude Impact Lab / agentes educacionais.